



Datenanalyse von Haushalts- und Gebäudelastprofilen

Distanzmaße, Prognosefehler und Mittelwerte im Kontext von Smart Meter Daten im Niederspannungsnetz

M.Sc. Marcus Voß

Leiter Anwendungszentrum Smart Energy Systems

WindNODE AP 8 – Quartierskonzepte und Smart City

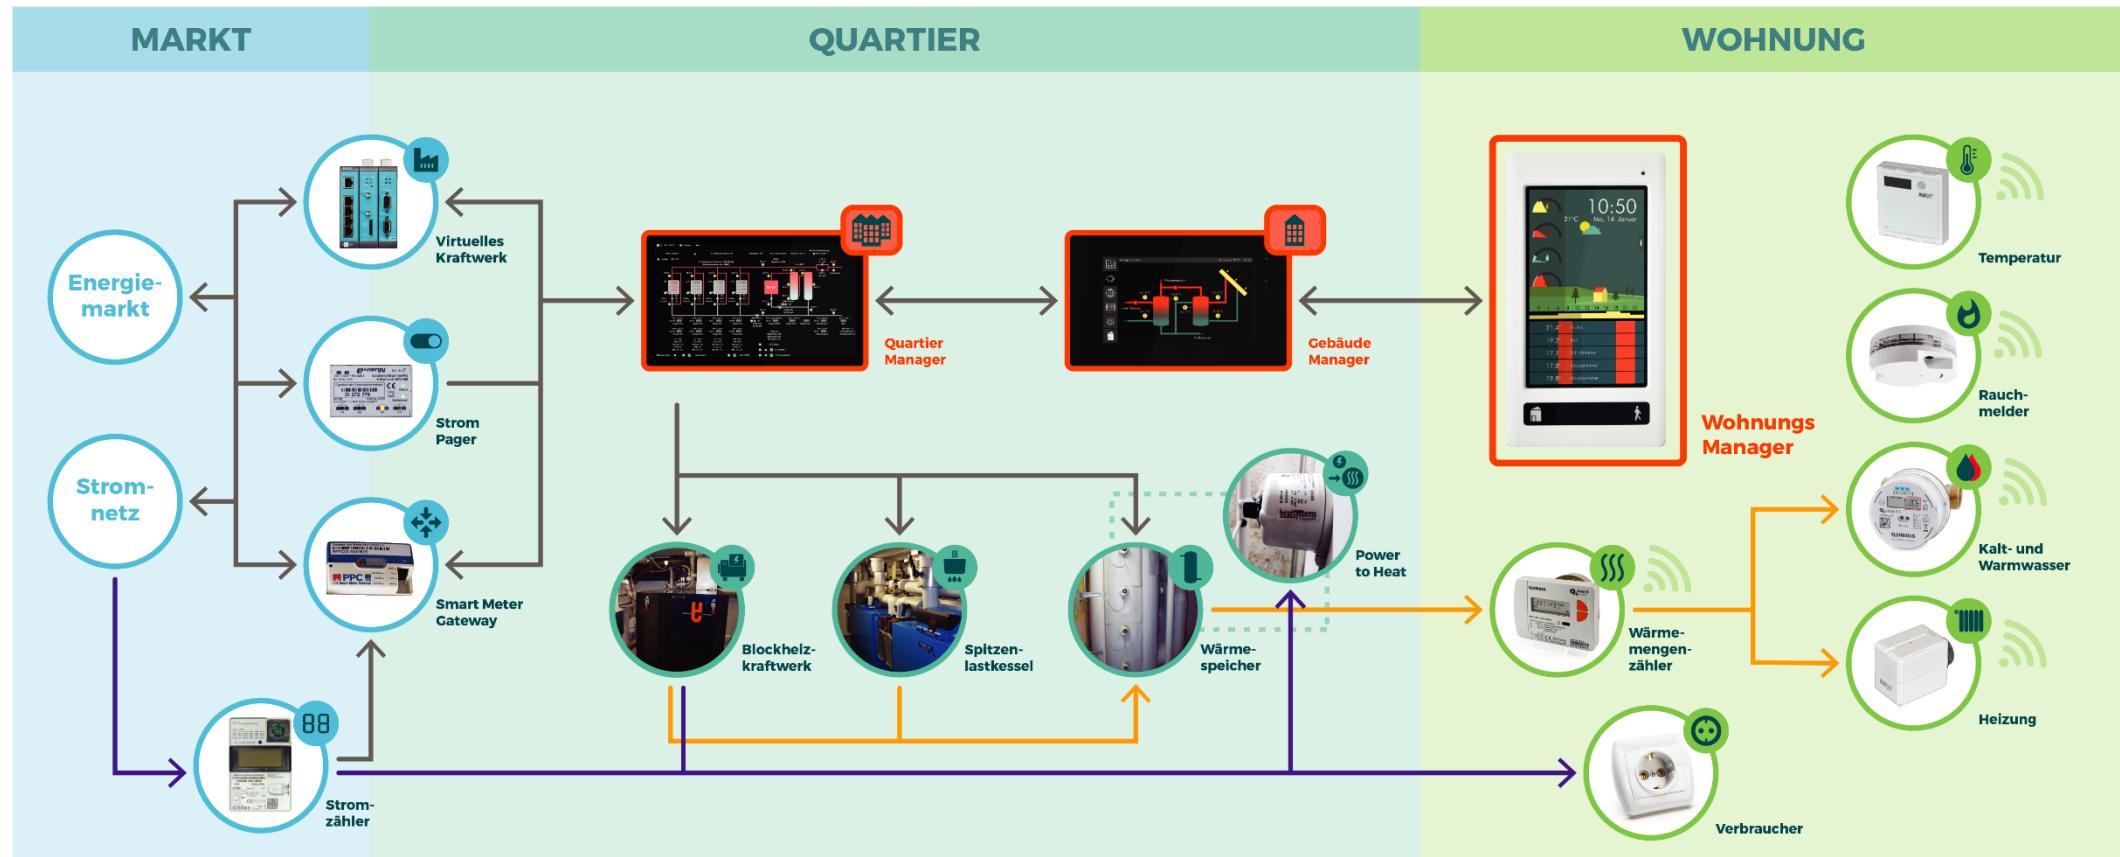


**Das Schaufenster für
intelligente Energie aus dem
Nordosten Deutschlands**

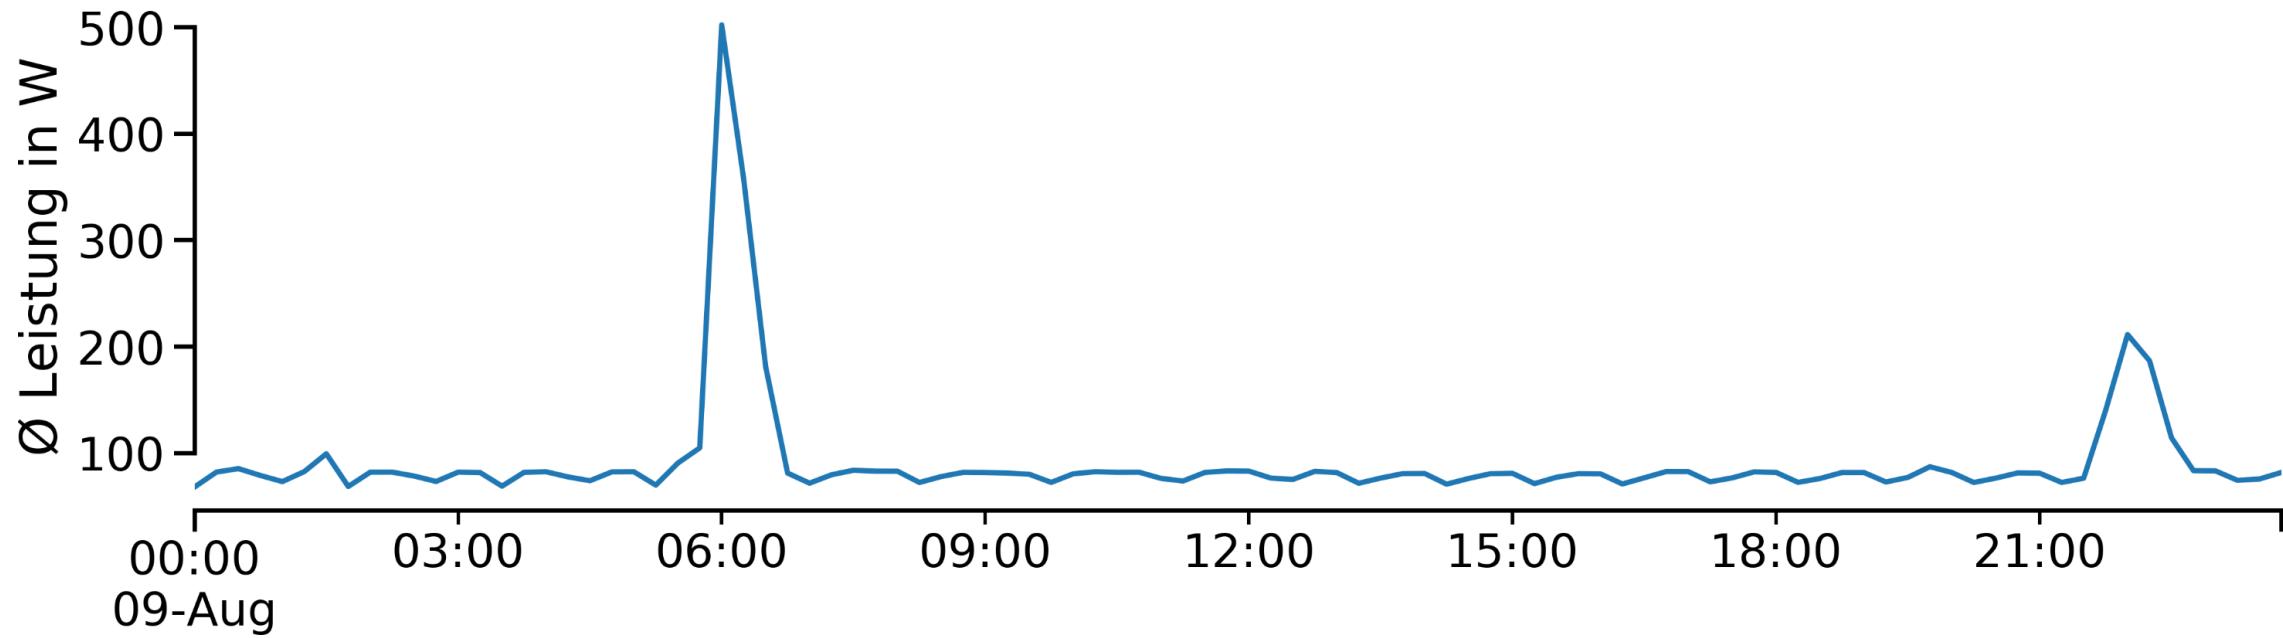
Quartierskonzepte - Prototypen der Smart City
Energiemanagementsysteme für Wohnquartiere und
zur Stabilisierung des Stromnetzes



Projektpartner:

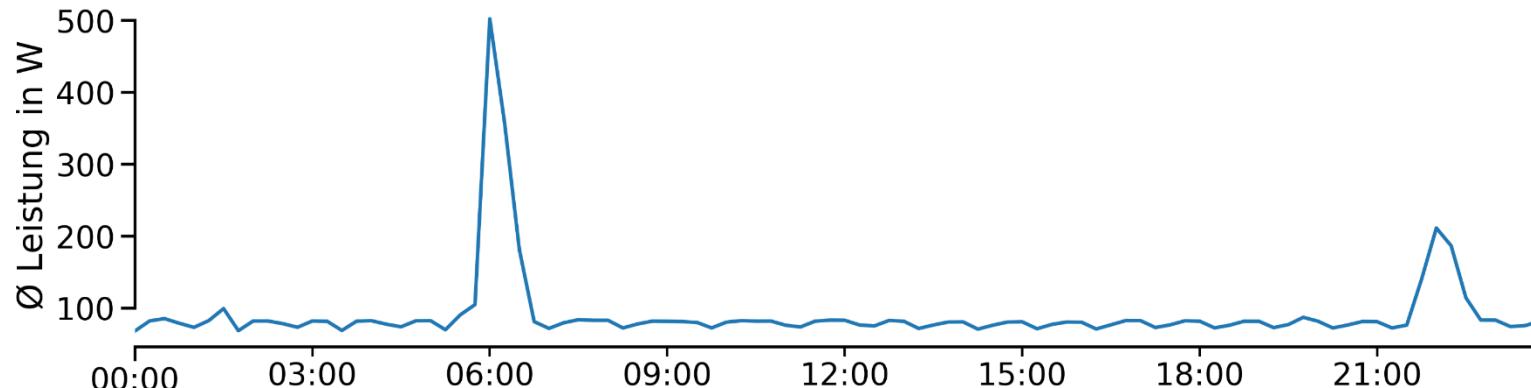


Ein typisches Smart Meter Lastprofil eines Haushalts in 15-minütiger Auflösung

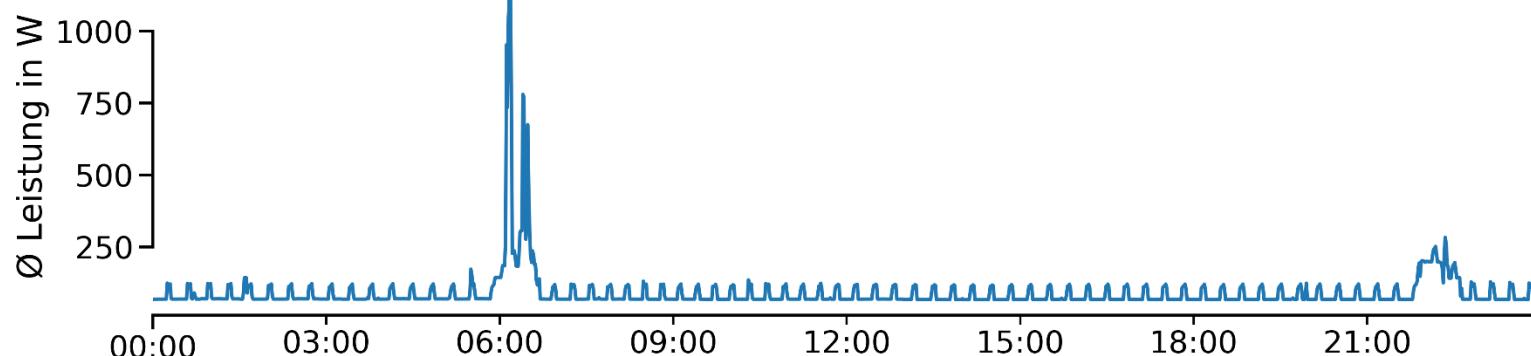


Lastprofil eines Haushalts in höheren Auflösungen

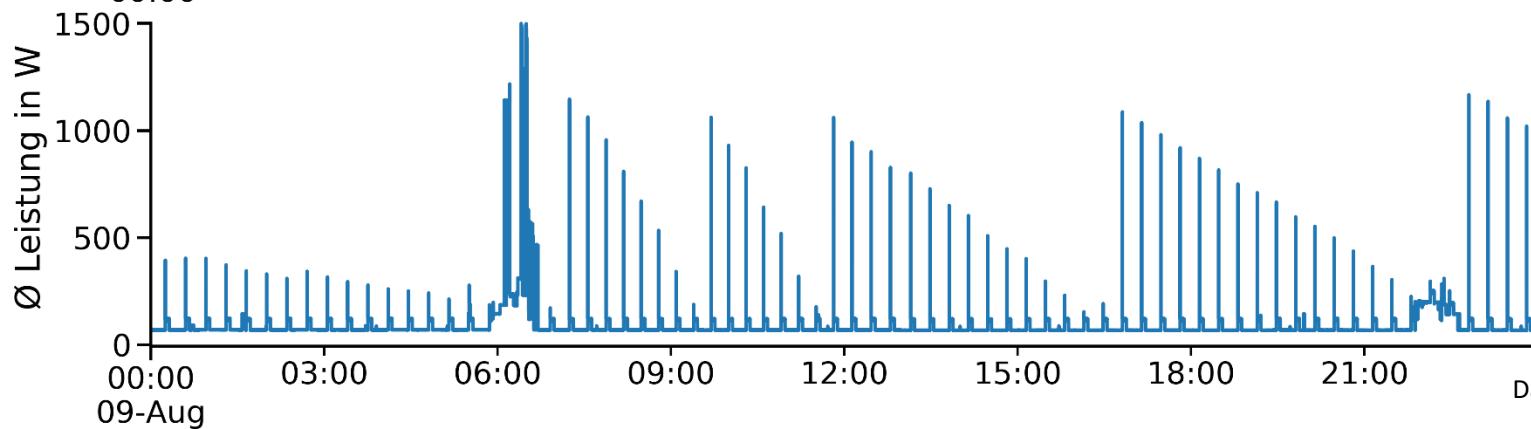
15-minütige
Auflösung



1-minütige
Auflösung



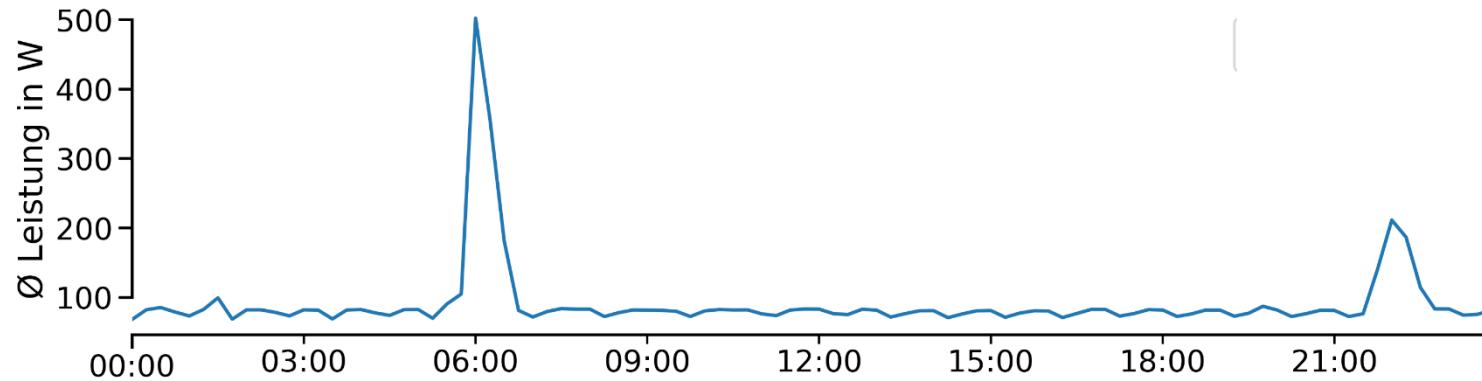
1-sekündliche
Auflösung



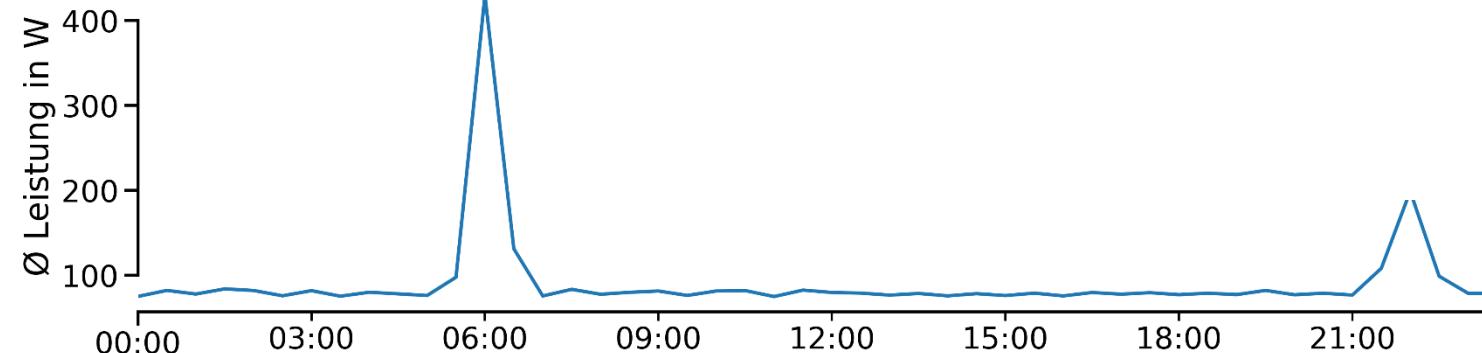
Daten: [ECO2014]

Lastprofil eines Haushalts in niedrigen Auflösungen

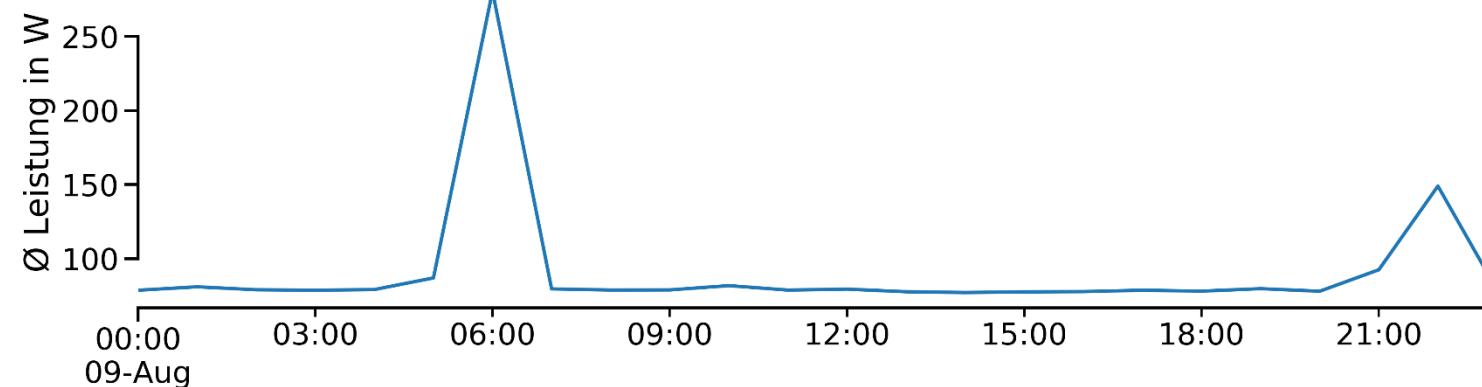
15-minütige
Auflösung



30-minütige
Auflösung



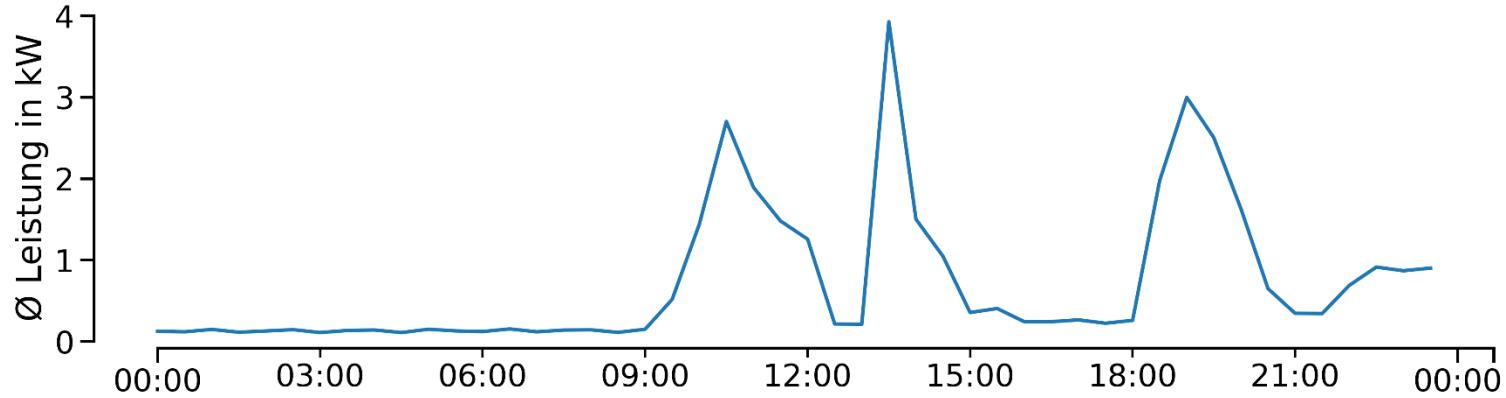
60-minütige
Auflösung



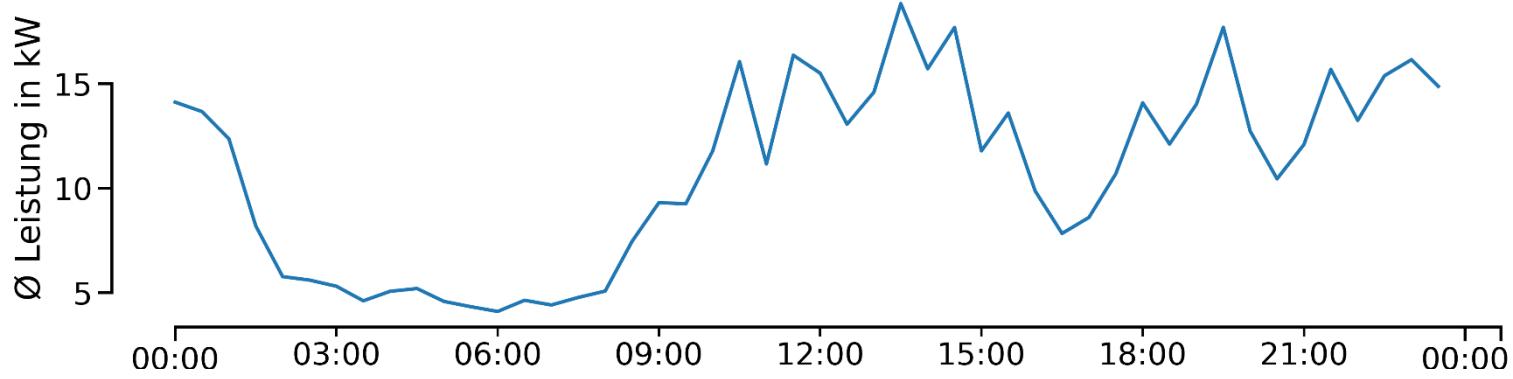
Daten: [ECO2014]

Lastprofile in verschiedenen Aggregationsstufen

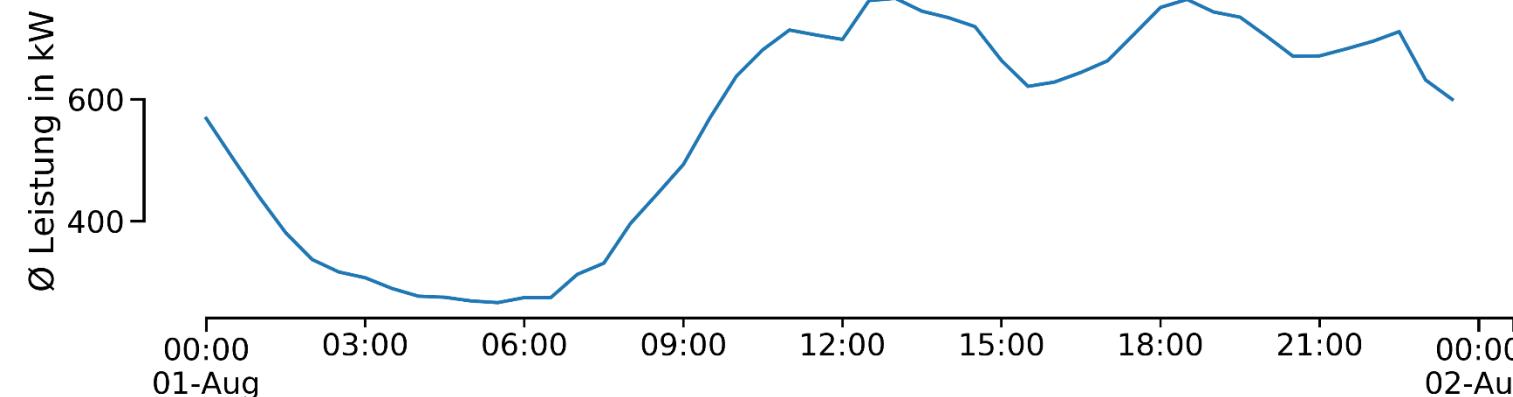
1 Haushalt



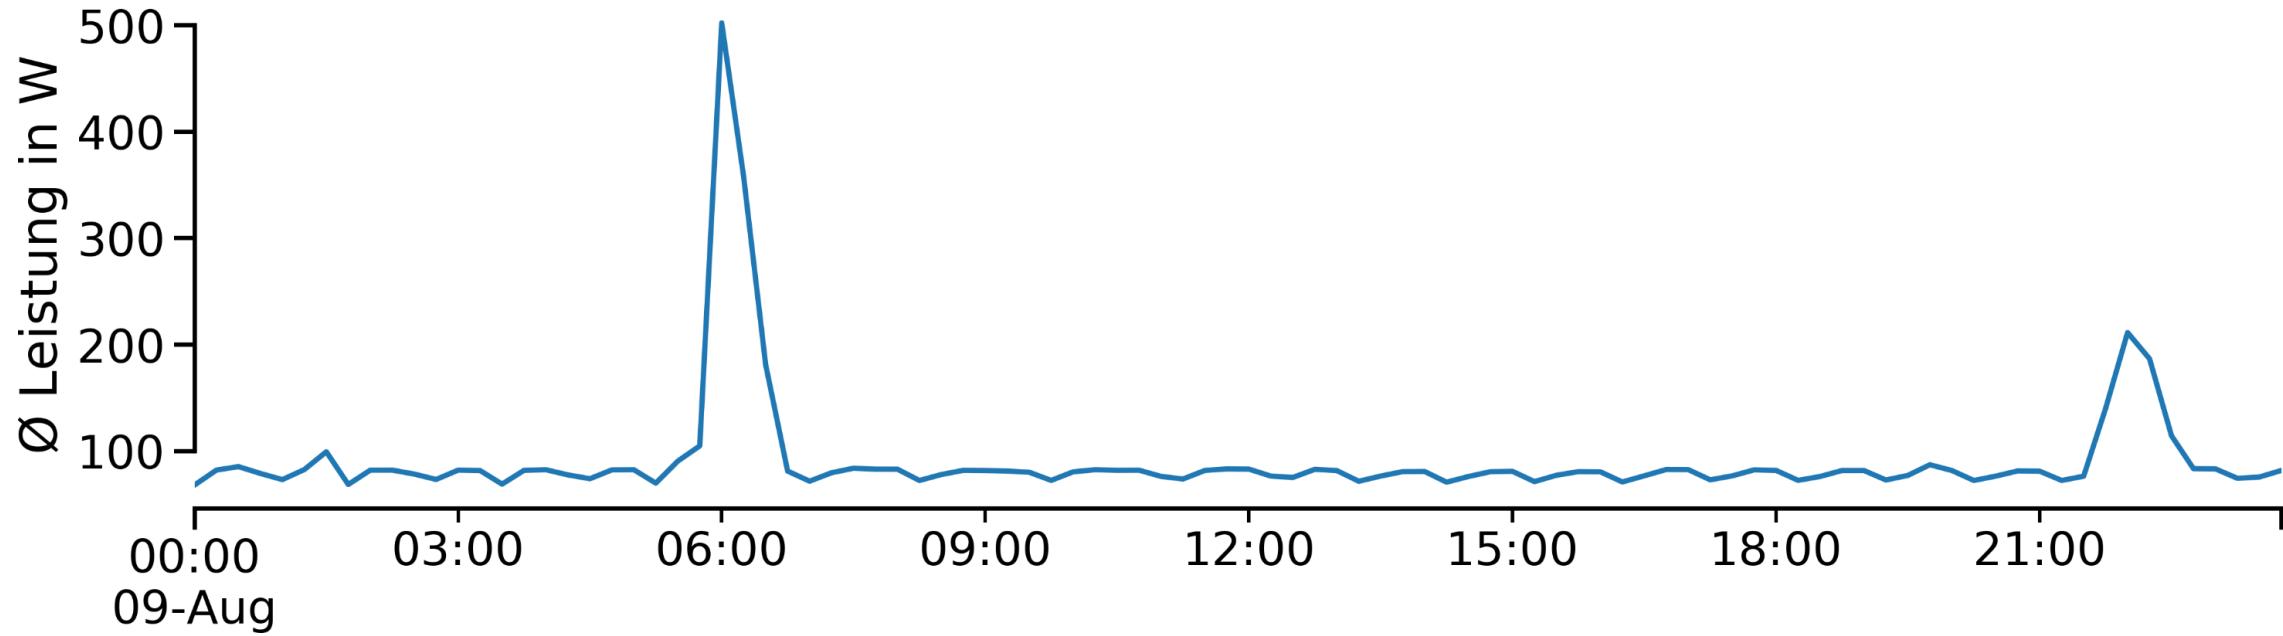
20 Haushalte



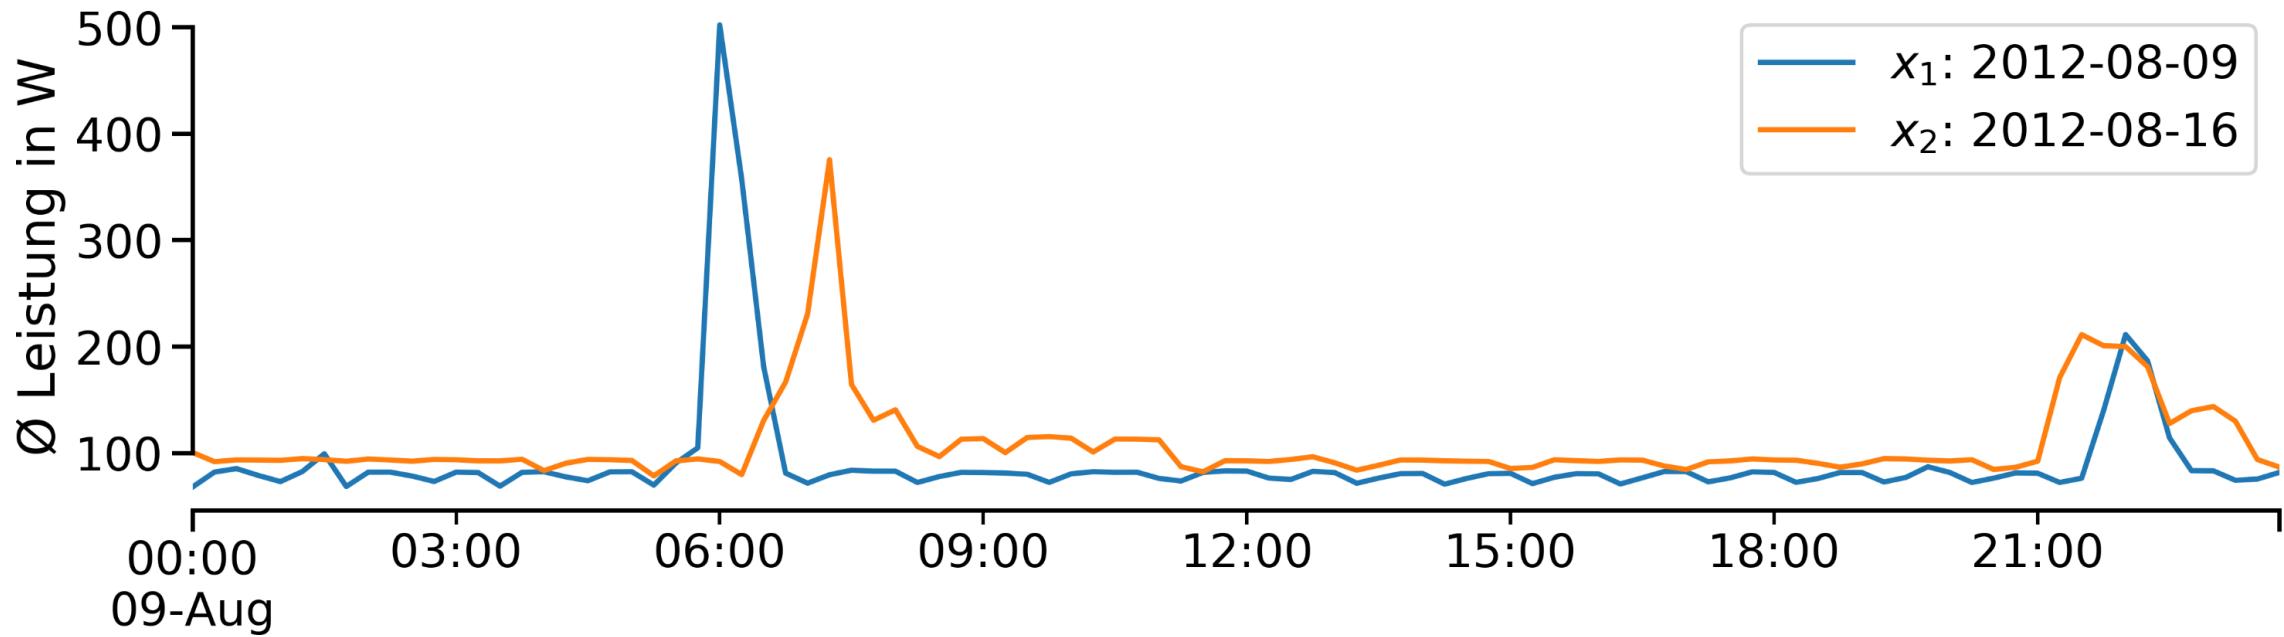
1000 Haushalte



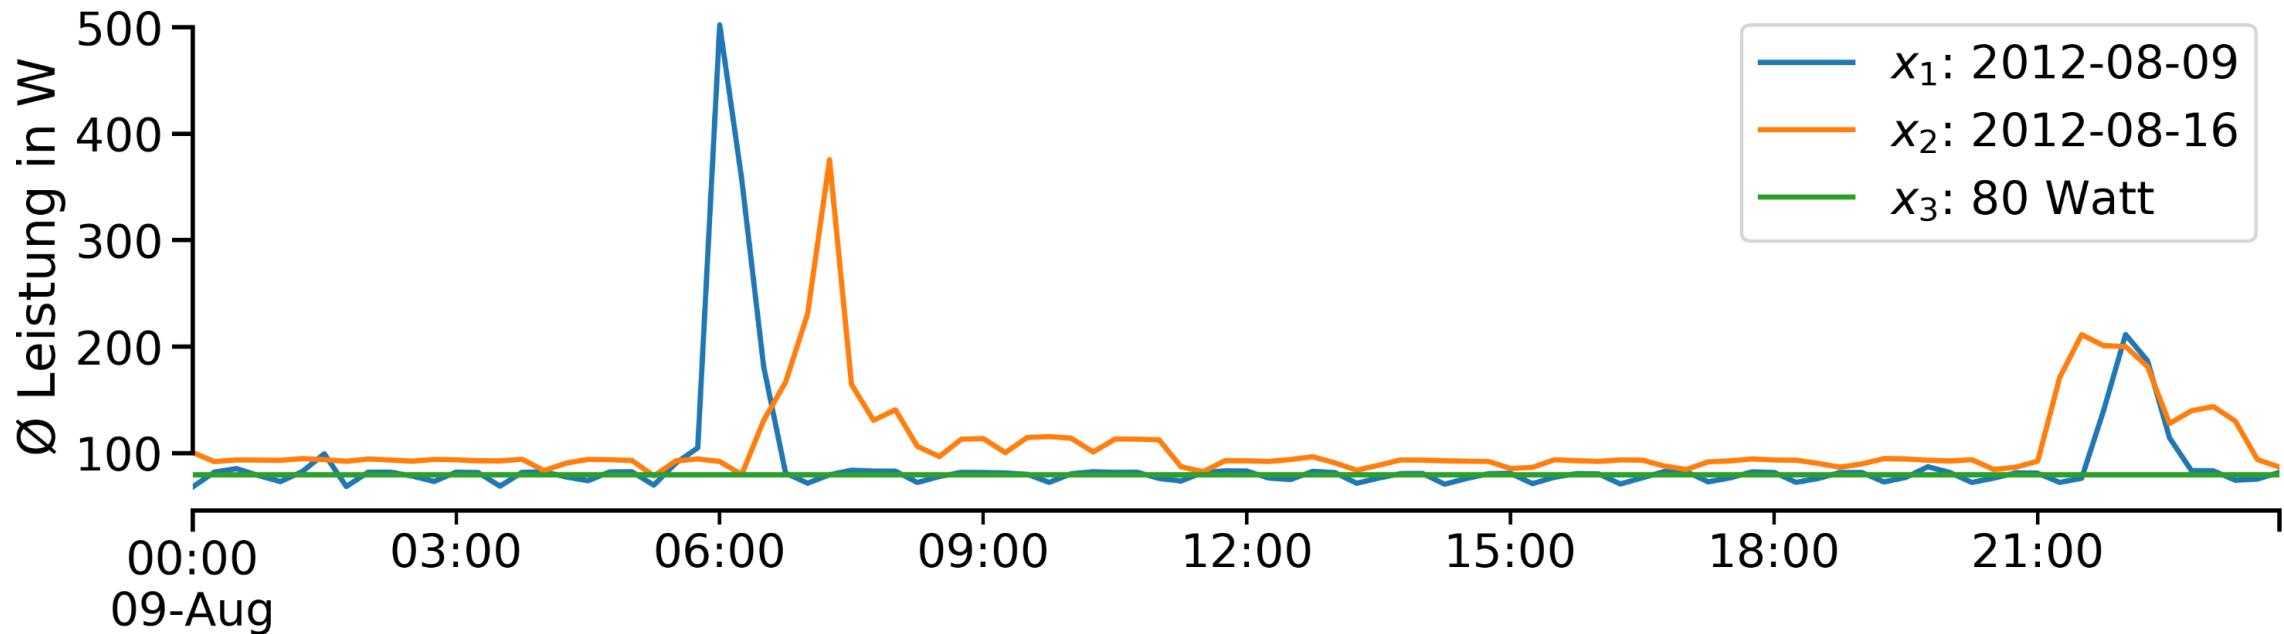
Wann sind Lastprofile sich ähnlich?



Wann sind Lastprofile sich ähnlich?



Wann sind Lastprofile sich ähnlich?



Euklidischer Abstand (L2-Norm):

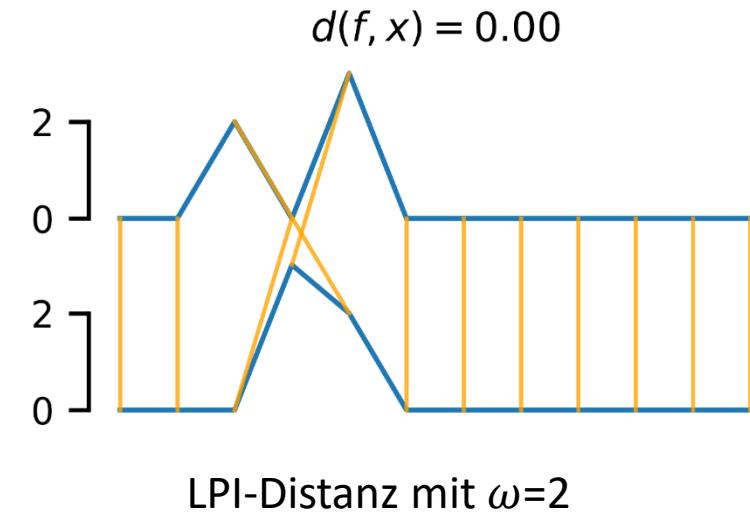
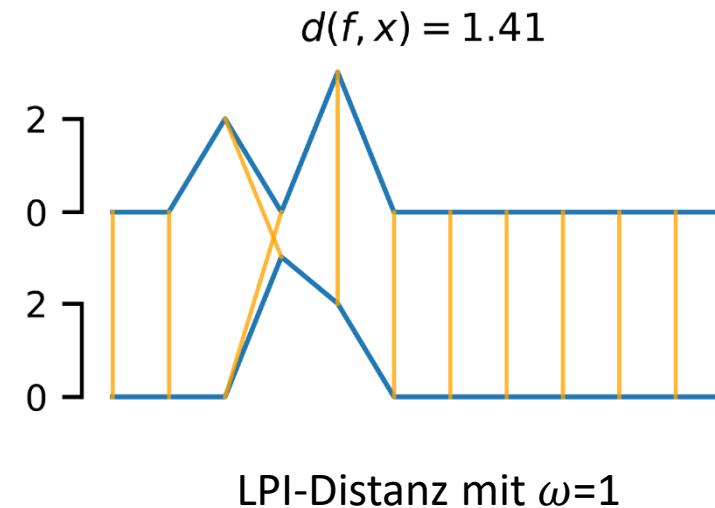
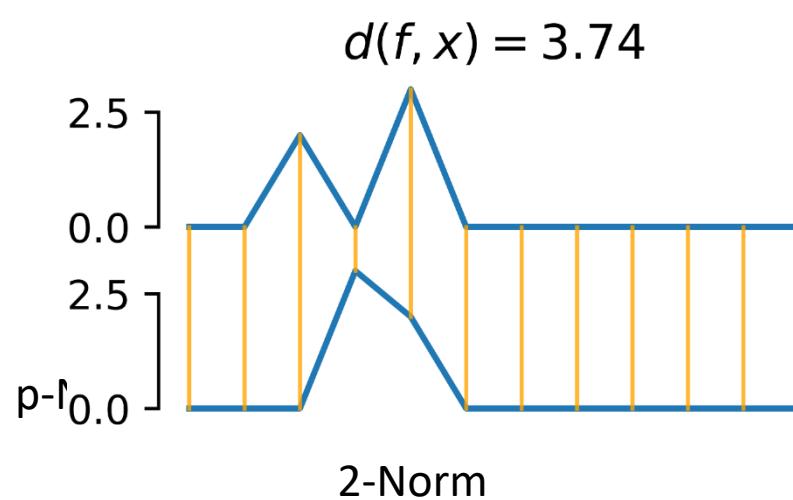
$$d(f, x) = \|f - x\| = \sqrt{\sum_{i=1}^n |f_i - x_i|^2}$$

$$d(x_1, x_2) : 669 \text{ W}$$

$$d(x_1, x_3) : 550 \text{ W}$$

Die angepasste p-Norm für Haushaltslastprofile

Für Haushaltslastprofile wurde die „angepasste p-Norm“, bzw. Local Permutation Invariant (LPI) Distanz definiert [Haben2014, Voss2019].



2-norm

$$E = \|f - x\|$$

LPI-Distanz

$$E_\omega = \min_{\pi \in \mathcal{P}} \|\pi f - x\|$$

Nomenklatur:

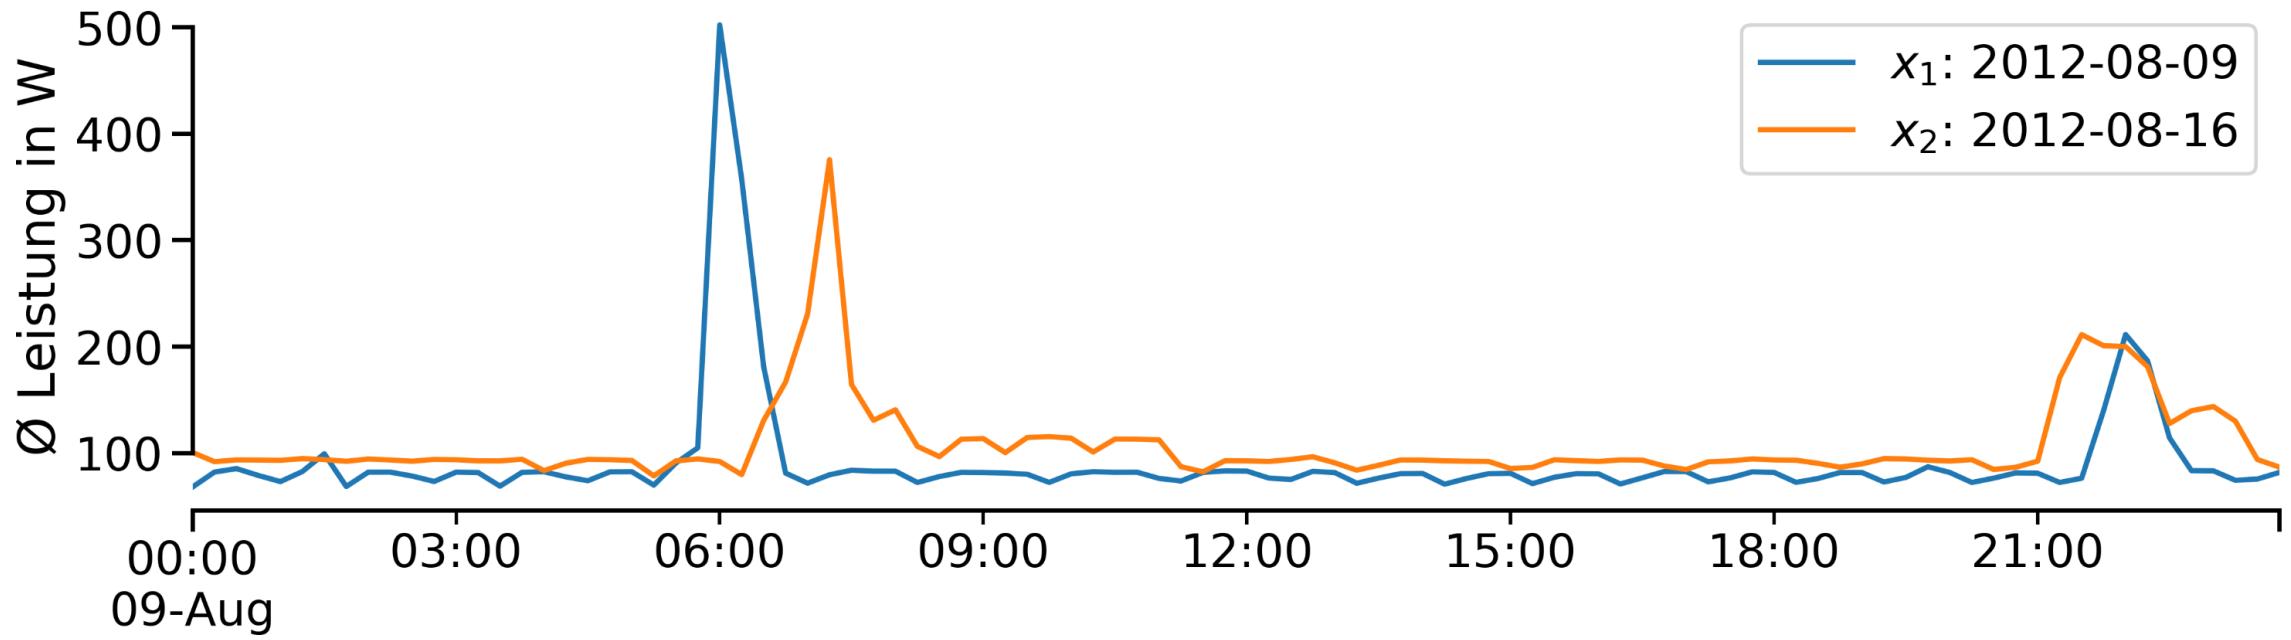
f Vektor der Größe n, die Prognose

x Vektor der Größe n, die Ist-Werte

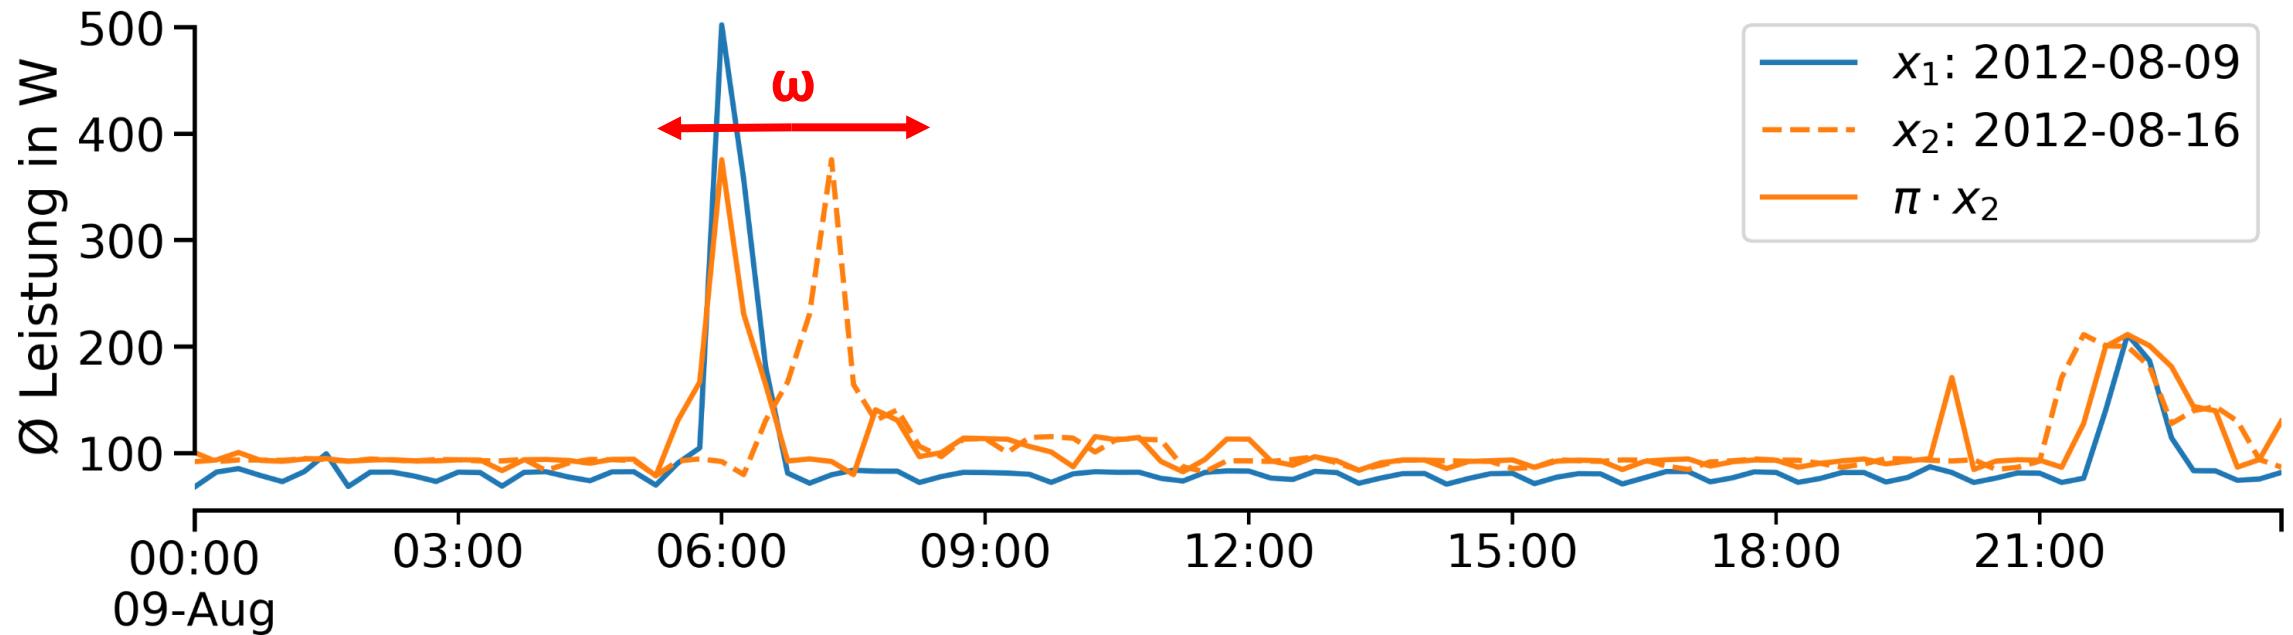
ω Parameter zur Begrenzung der Permutationen

\mathcal{P} Menge der von ω begrenzten Permutationsmatrizen
 π p-norm minimierende Permutationsmatrix

Die angepasste p-Norm für Haushaltslastprofile



Die angepasste p-Norm für Haushaltslastprofile



$$d(\mathbf{x}_1, \mathbf{x}_2) : 668,7 \text{ W}$$

$$d(\mathbf{x}_1, \mathbf{x}_3) : 549,6 \text{ W}$$

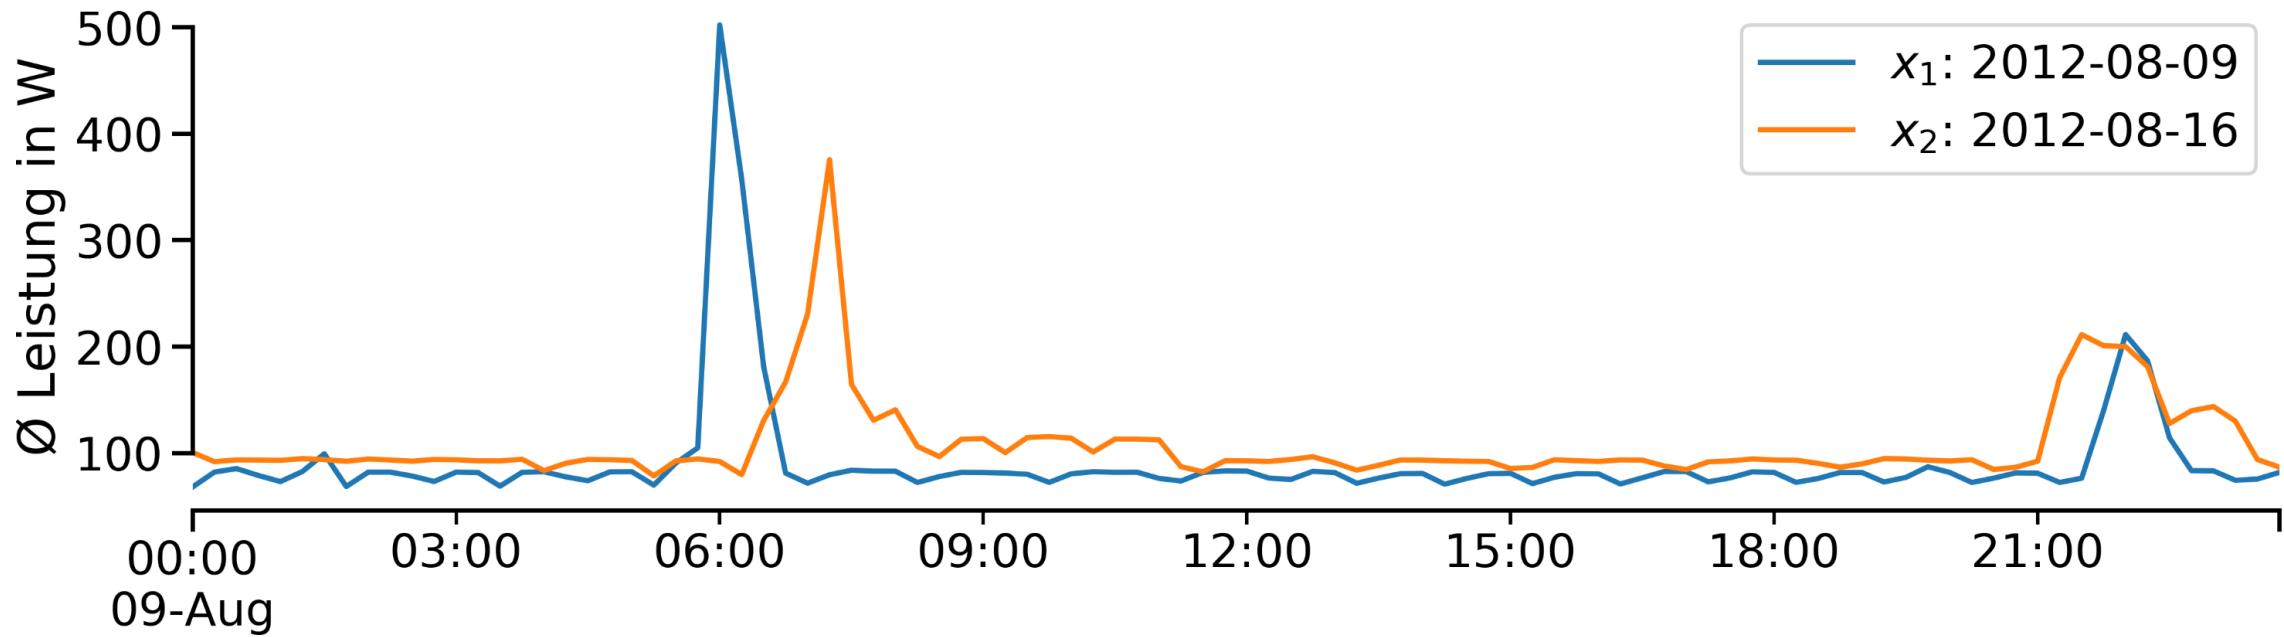


$$d_{LPI}^{\omega=5}(\mathbf{x}_1, \mathbf{x}_2) : 308,3 \text{ W}$$

$$d_{LPI}^{\omega=5}(\mathbf{x}_1, \mathbf{x}_3) : 549,6 \text{ W}$$

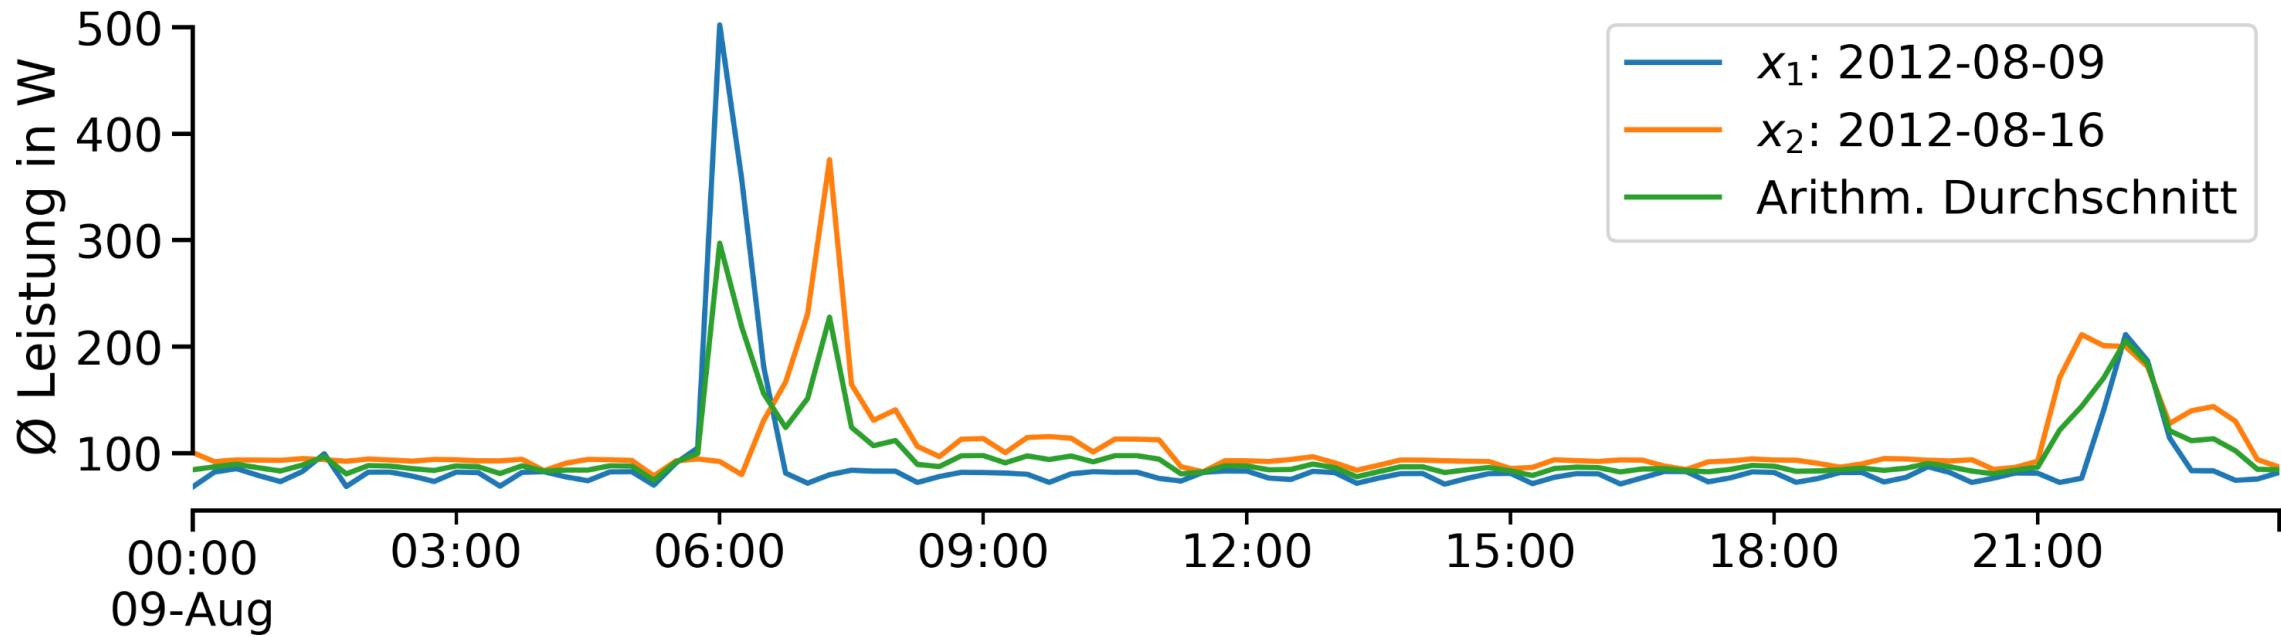
Was ist ein passender „Durchschnitt“ für Haushaltslastprofile?

Ein Durchschnitt von n Lastprofilen ist ein Profil mit minimalem *Abstand* zu den n Lastprofilen.



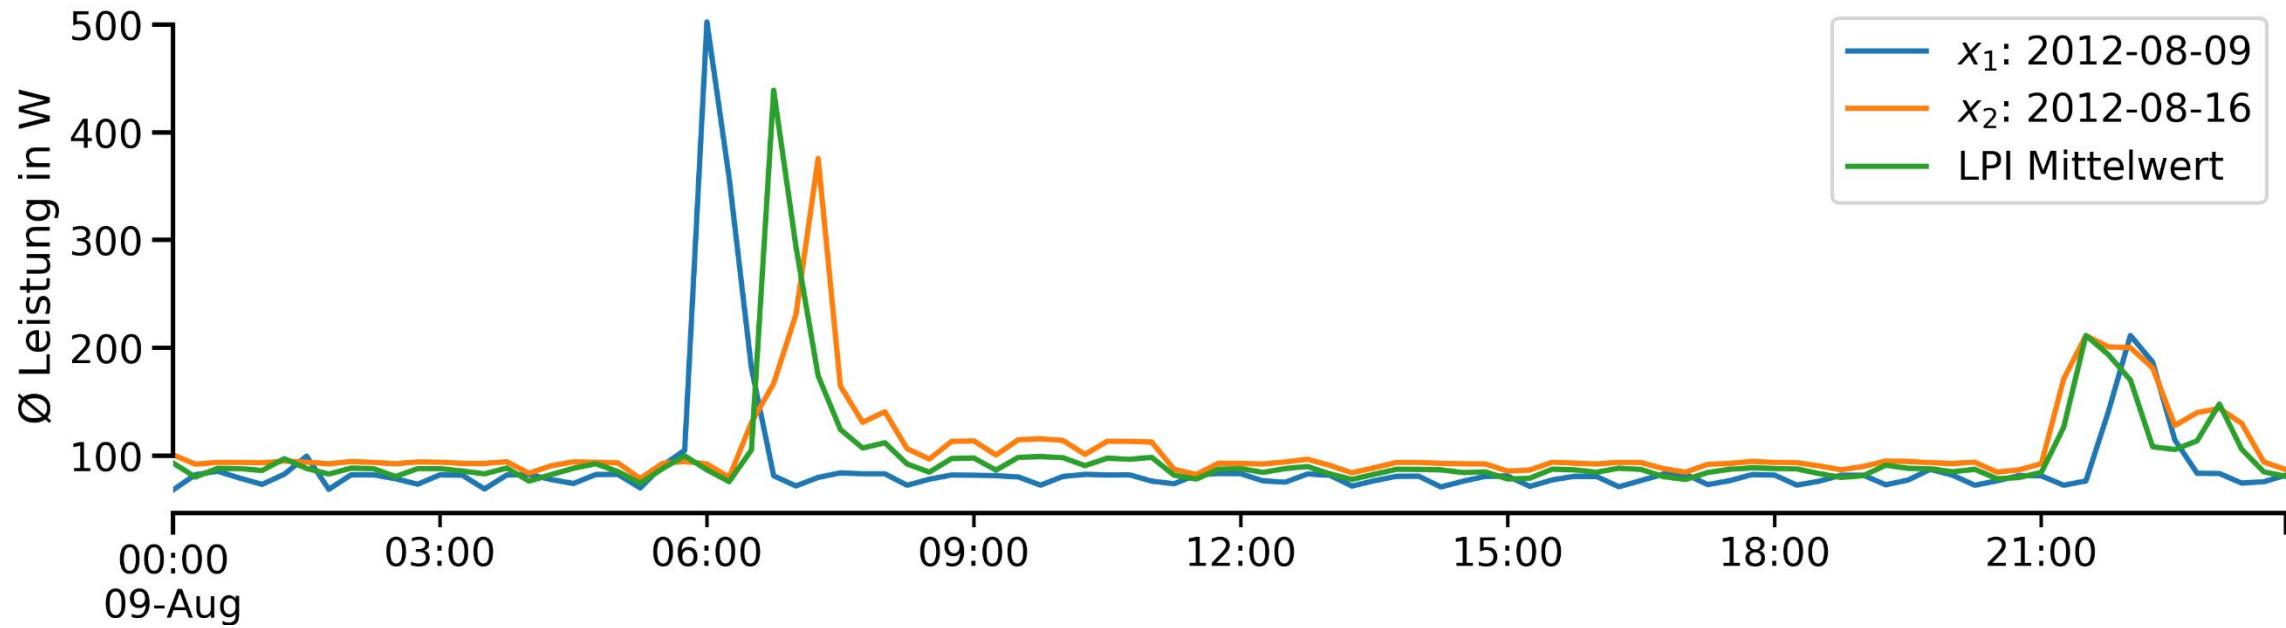
Was ist ein passender „Durchschnitt“ für Haushaltslastprofile?

Der arithmetische Mittelwert minimiert den Euklidischen Abstand.



Was ist ein passender „Durchschnitt“ für Haushaltslastprofile?

Der Local Permutation Invariant (LPI) Mittelwert minimiert die angepasste p-Norm [Voss2019].



Warum sollten mich Distanzen und Durchschnitte interessieren?

*K-Nearest
Neighbor*

ARIMA

k-Means Clustering

*Multivariate
Lineare
Regression*

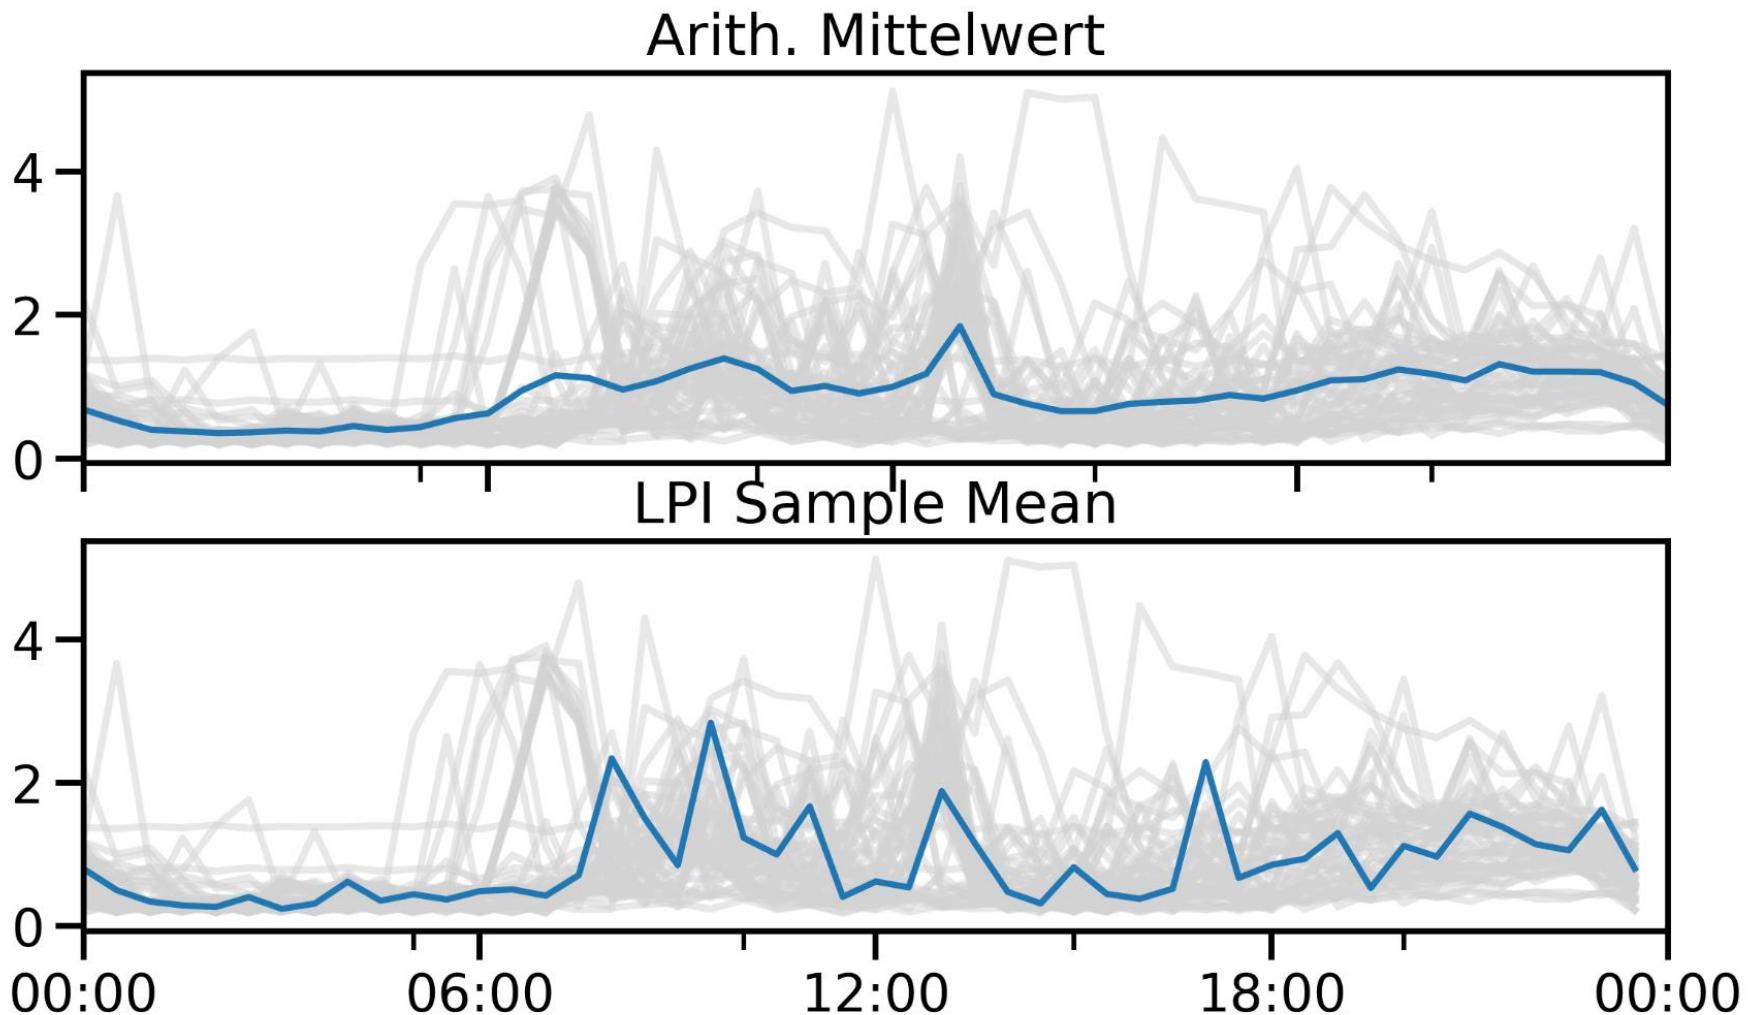
*Support Vector
Machine*

Holt-Winters

*Seasonal
Exponential
Smoothing*

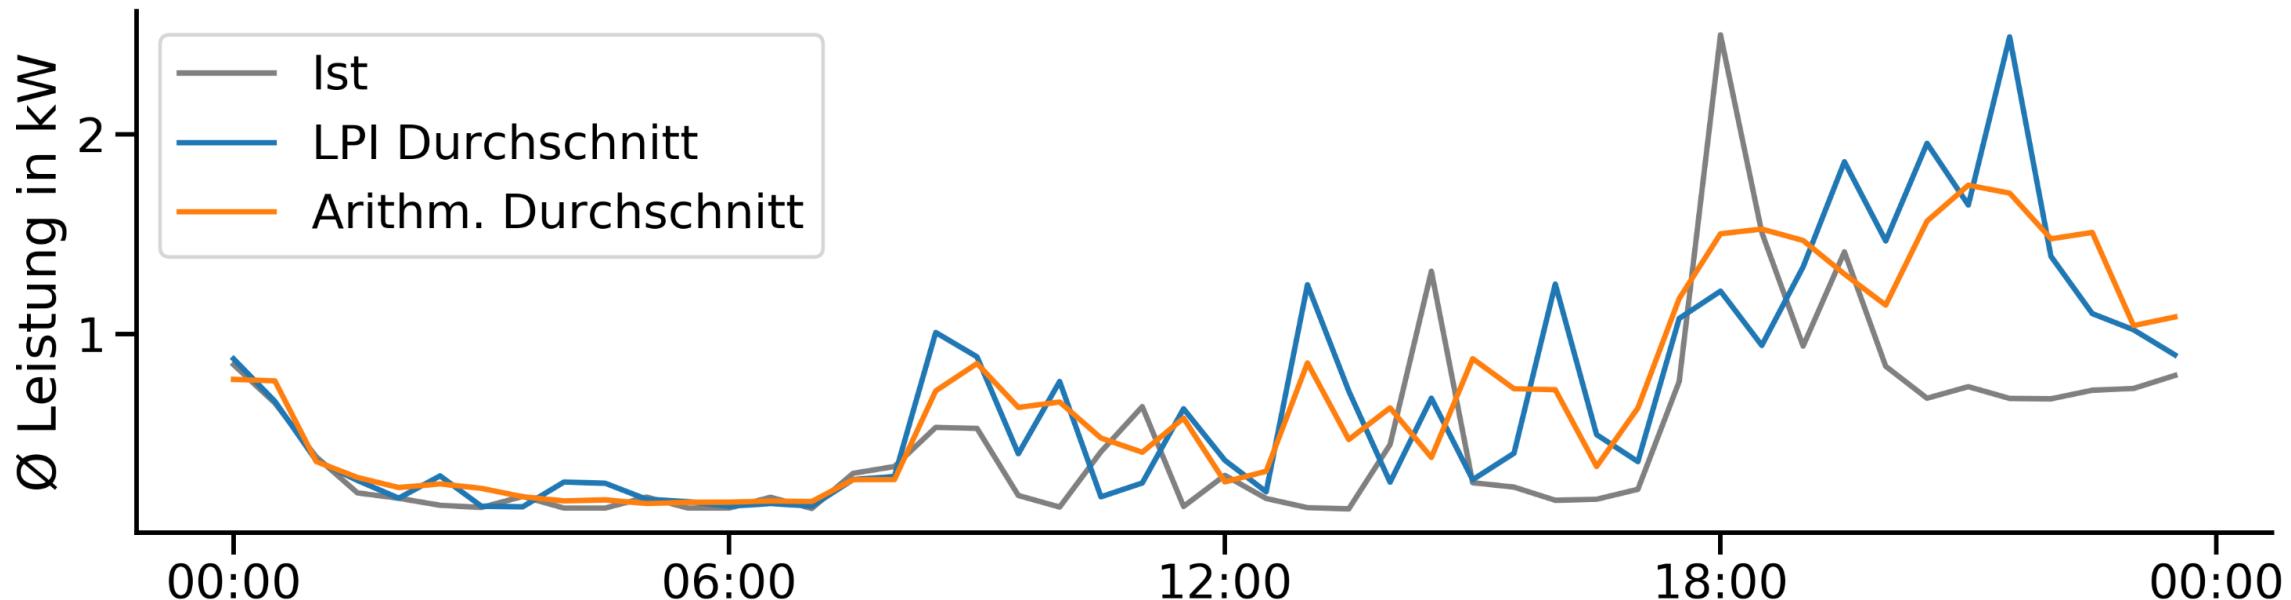
Fallstudie 1: K-Means Clustering der Lastprofile eines Haushalts

Vergleich von
Clustermittelpunkten
eines Clusters nach k-
Means Clustering auf
Lastgängen eines
Haushalts mit
verschiedenen
Distanzmaßen (k=7).



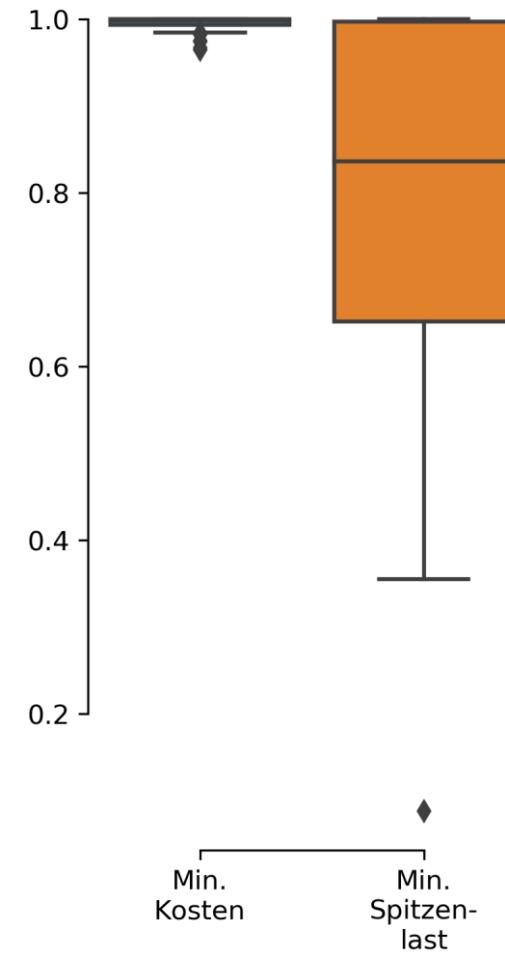
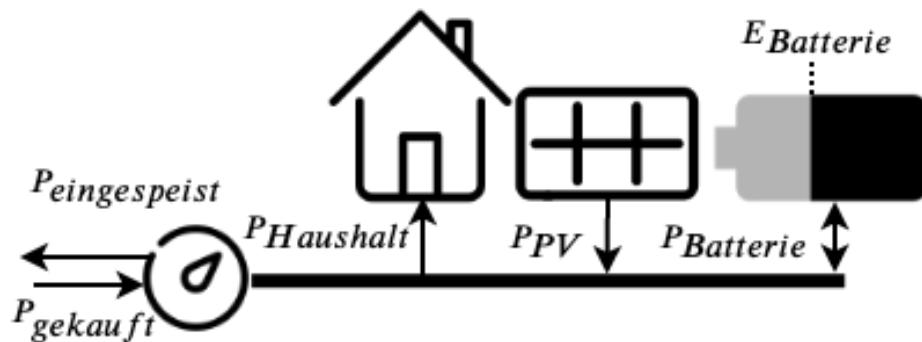
Fallstudie 2: Kurzfristige Last-Prognose

Beispielhafte Prognose für einen Tag mit gleitendem Durchschnitt der letzten 6 Wochen



Fallstudie 2: Kurzfristige Last-Prognose

- Die Wahl der “besten” Prognose muss im Kontext des eigentlichen Anwendungsfalles getroffen werden.
- So kann in einer Fallstudie mit Haushalt, Solaranlage und Batteriespeicher die langfristige Lastspitze im Schnitt um knapp 25% verringert werden kann, wenn die LPI Distanz minimiert wird, während für die Kostenminimierung die RMSE-minimierende Prognose die bessere Prognose darstellt.

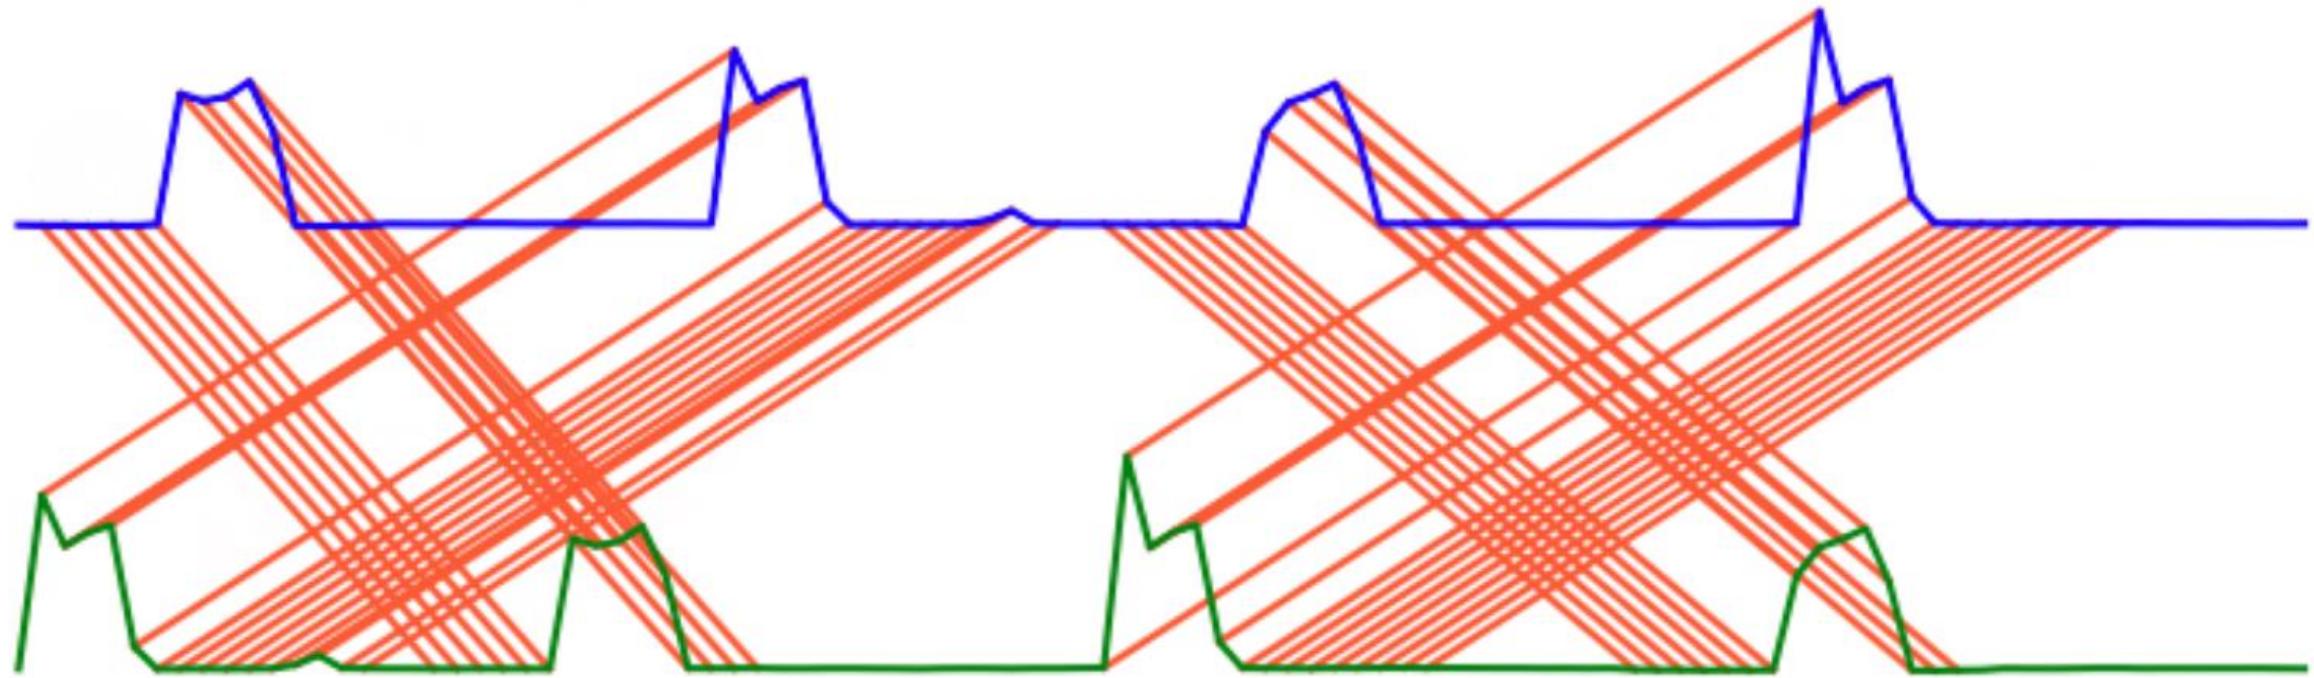


Relative Veränderung gegenüber der Minimierung des RMSEs ($N=100$).

Zusammenfassung und Fazit

- ▶ Niedrig aggregierte Lastprofile unterscheiden sich stark von hochaggregierten Lastprofilen (fluktuierender und intermittierender).
- ▶ Algorithmen die auf klassischen Distanz- und Fehlermaßen basieren können daher auf Smart Meter Daten zu ungewollten (?) Ergebnissen führen.
- ▶ Alternativen wie DTW und der Durchschnitt DBA sind in anderen Zeitreihendomänen schon länger etabliert.
- ▶ Für Smart Meter Daten wurden allerdings auch spezielle Distanzen und Durchschnitte vorgestellt [Haben2014, Voss2019].
- ▶ Für einen spezifischen Anwendungsfall sollte daher die Wahl der Abstandsmaße, der dazugehörigen Durchschnitte und das „richtige“ Fehlermaß im Kontext des eigentlichen Problems beachtet werden!

Aktuelle Arbeit: Entwicklung eines Maßes für sehr hoch aufgelöste Daten



Diskussion? Sprechen Sie mich gerne an!

- ▶ Arbeiten Sie schon analytisch mit niedrig aggregierten Smart Meter Daten (z.B. aus Haushalten, Gebäuden, Produktionsprozessen)?

- ▶ Was haben Sie für typische Anwendungsfälle (Clustering, Klassifizierung, Regression, ...) und nutzen Sie angepasste Methoden (z.B. mit DTW)?



Get In Touch

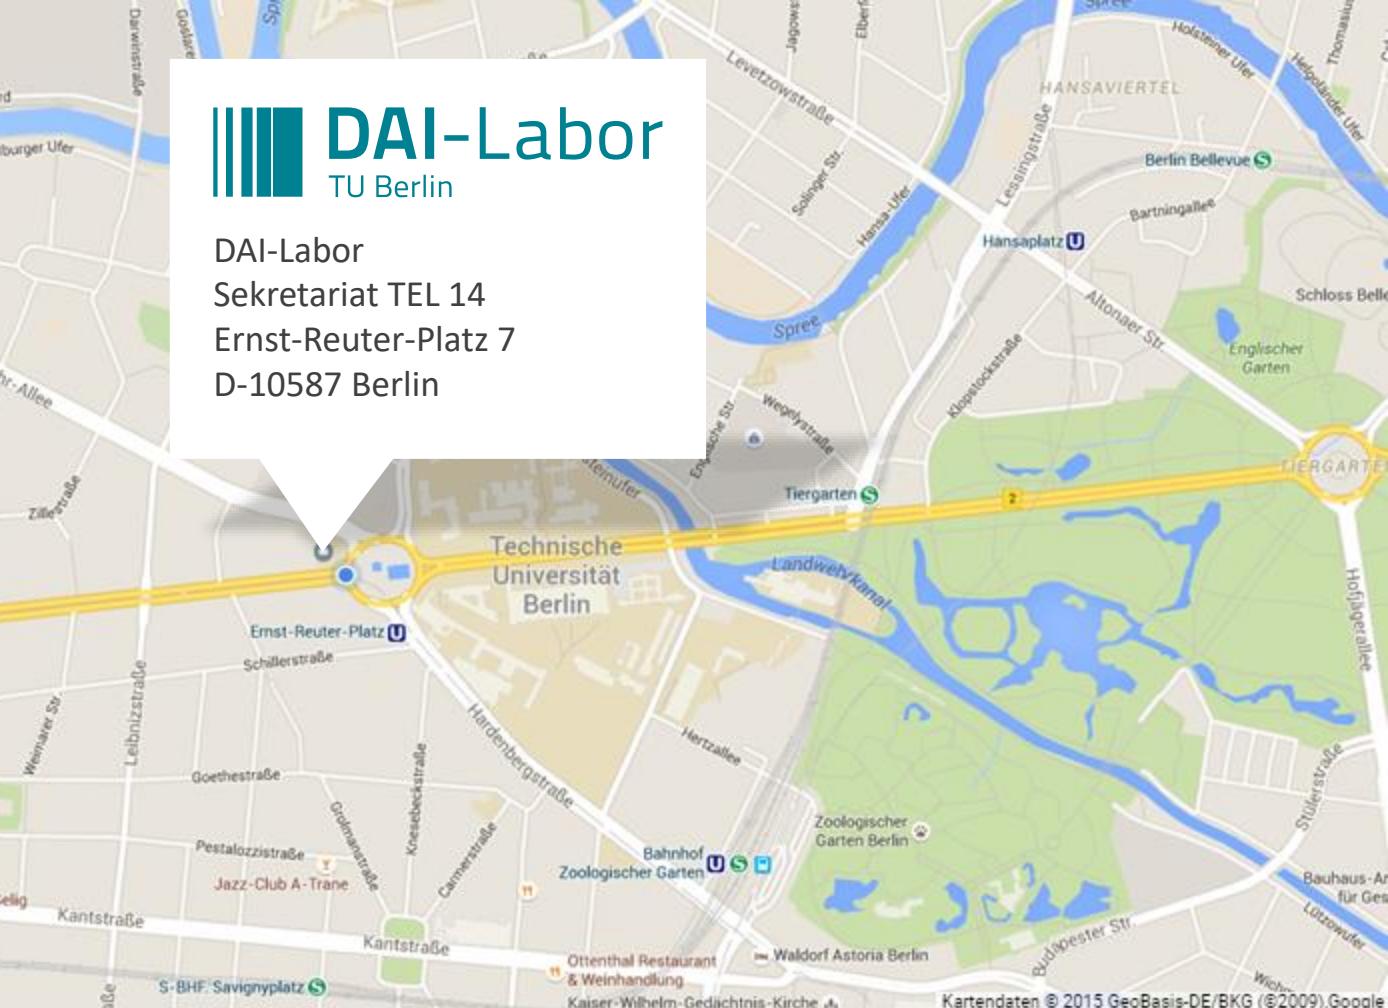


Marcus.voss@dai-labor.de

Marcus Voß

DAI-Labor
TU Berlin

DAI-Labor
Sekretariat TEL 14
Ernst-Reuter-Platz 7
D-10587 Berlin



+49 30 - 314 74060

Referenzen

- ▶ [CER2012] Commission for Energy Regulation (2012). CER Smart Metering Project - Electricity Customer Behaviour Trial, 2009-2010 [dataset]. Irish Social Science Data Archive.
- ▶ [ECO2014] C. Beckel, W. Kleiminger, R. Cicchetti, T. Staake, and S. Santini (2014) The ECO Data Set and the Performance of Non-Intrusive Load Monitoring Algorithms. In: Proceedings of the 1st ACM International Conference on Embedded Systems for Energy-Efficient Buildings (BuildSys 2014).
- ▶ [Gusfield1997] Dan Gusfield (1997): Algorithms on strings, trees and sequences: computer science and computational biology, 1997.
- ▶ [Haben2014] Haben, S., Ward, J., Greetham, D. V., Singleton, C., & Grindrod, P. (2014). A new error measure for forecasts of household-level, high resolution electrical energy consumption. International Journal of Forecasting.
- ▶ [Voss2018] Marcus Voß, Asmaa Haja, Sahin Albayrak (2018). Adjusted Feature-Aware k-Nearest Neighbors: Utilizing Local Permutation-Based Error for Short-Term Residential Building Load Forecasting. In: IEEE International Conference on Communications, Control, and Computing Technologies for Smart Grids (SmartGridComm).
- ▶ [Voss2019] Marcus Voß, Brijnesh Jain, and Sahin Albayrak (2019). Averaging Household Load Profiles: Subgradient-based Approximations of the Local Permutation Invariant Sample Mean. In: IEEE PowerTech 2019.